

Предсказание ценовой функции смартфонов на российском рынке

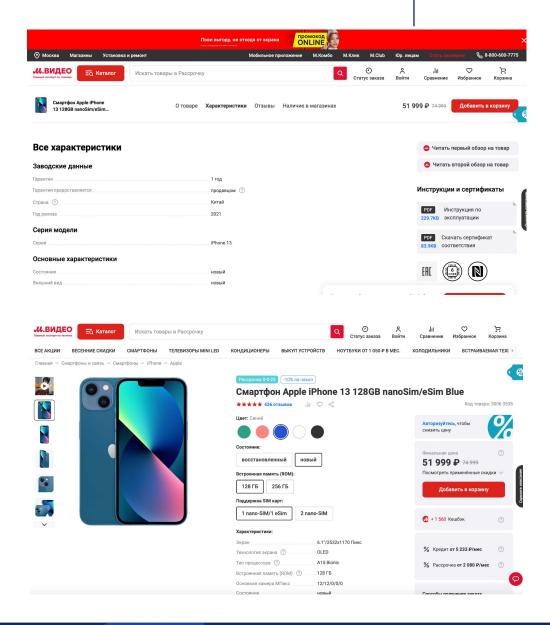
Тевс Анна БЭАД223

Сбор данных

Было решено использовать достаточно аккуратное и подробное описание характеристик телефонов с **Мвидео**. (Запросы по внутреннему **АРІ сайта**)

Признаки:

- ID: name, brand
- <u>Size:</u> Экран (Дюймы), Габаритные размеры (В*Ш*Т/В*Ш*Г мм), Вес (г)
- <u>Resolution:</u> Камера (МПикс), Разрешение экрана, Разрешение видеосъемки (Пикс), Зум (х)
- <u>Inside:</u> Технология экрана, Яркость (кд/кв.м), Частота обновления экрана (Гц), Количество ядер (шт), Память (ГБ), Количество камер (шт), Степень защиты (IPXY), Мощность блока питания (Вт), Емкость аккумулятора (мАч)
- Outside/features: Безрамочный, Съемка видео в портретном режиме, Оптическая стабилизация, Поддержка симкарт, Поддержка стандартов, Поддержка WiFi, Технология NFC, Сенсор распознавания лица, Сканер отпечатка пальца, Материал корпуса, Блок питания, Кабель, Чехол
- Others: Гарантия, Страна, Год релиза
- <u>Targets</u>: **salePrice**, basePrice





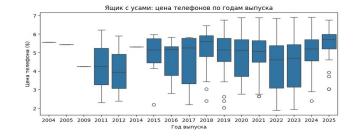
Обработка и анализ данных

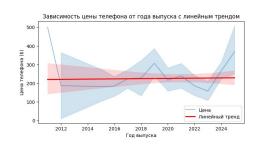
Проблема: много характеристик

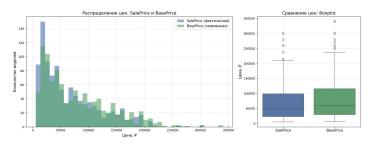
Решение:

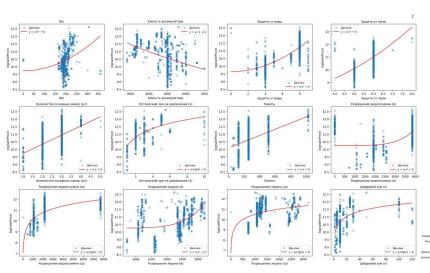
- Анализ nan
- Графики
- а) для дамми в основном box-plot
- b) для количественных logreg, scatter, lineplot
- с) для категориальных всё ранее упомянутое + частота через histplot
- Построения "локальных" регрессия (для выявления незначимых на первых этапах)
- Здравый смысл! (+ ориентир на будущие предположения)

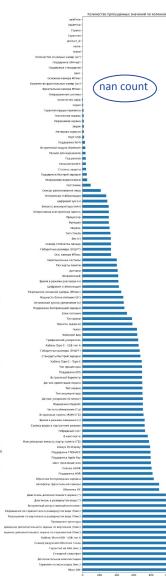














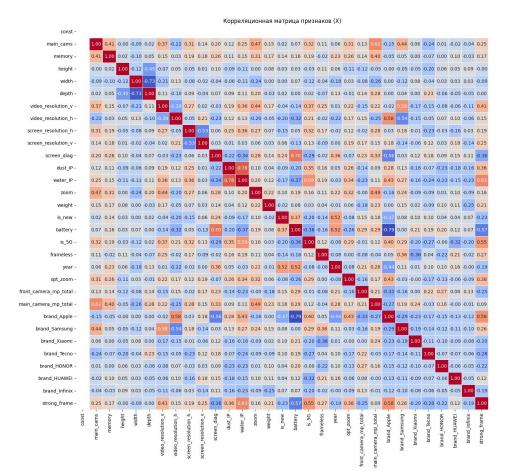
Мультиколлинеарность

Correlation matrix VIF

Изменения:

- новый признак (strong_frame = разность наличия металла и пластика в корпусе)
- PCA на разрешение видео (h/v)
- Периметр
- IP (сумма влагозащиты и защиты от пыли)

| | feature | VIF |
|----|----------------------------------|----------|
| 0 | brand_Apple | 9.870583 |
| 1 | depth | 8.542697 |
| 2 | width | 6.542193 |
| 3 | battery | 5.462524 |
| 4 | water_IP | 5.379111 |
| 5 | strong_frame | 4.442066 |
| 6 | brand_Samsung | 4.153618 |
| 7 | height | 3.767653 |
| 8 | dust_IP | 3.292562 |
| 9 | main_camera_mp_total | 3.267930 |
| 10 | <pre>video_resolution_h</pre> | 3.225892 |
| 11 | screen_resolution_h | 3.103757 |
| 12 | is_5G | 3.096500 |
| 13 | screen_resolution_v | 3.052016 |
| 14 | main_cams | 2.988218 |
| 15 | screen_diag | 2.631178 |
| 16 | <pre>video_resolution_v</pre> | 2.430543 |
| 17 | brand_HUAWEI | 2.293055 |
| 18 | zoom | 2.168234 |
| 19 | brand_Xiaomi | 2.134353 |
| 20 | year | 2.130298 |
| 21 | opt_zoom | 2.057209 |
| 22 | <pre>front_camera_mp_total</pre> | 2.022238 |
| 23 | brand_Tecno | 1.776077 |
| | | |
| 27 | memory | |
| 28 | brand_Infinix | 1.414392 |
| 29 | weight | 1.403383 |
| 30 | const | 1.000000 |



Гетероскедастичность

Тесты:

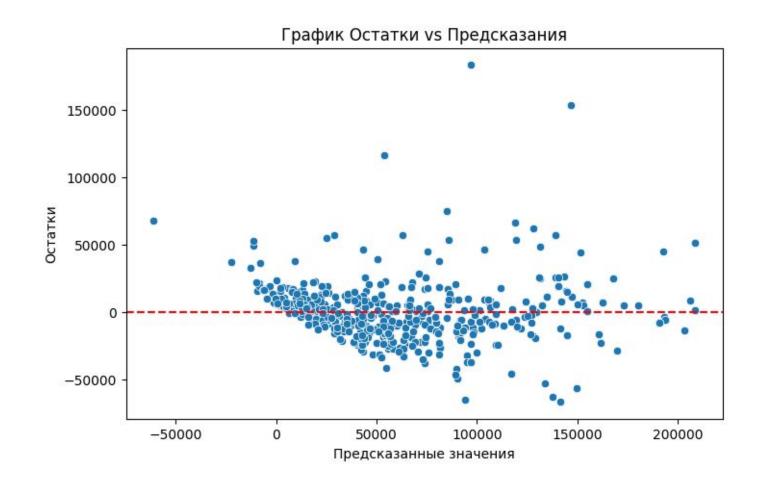
- Визуальный (облако точек)
- Уайта (F-Test p-value: 0.0000)

Проблема решена использование стандартных ошибок в форме Уайта

(っ ~^)っ (cov_type='HC3')

Also tried:

- Изменить функциональную форму на этом этапе
- Полулогарифмическую модель



Выбор функциональной формы

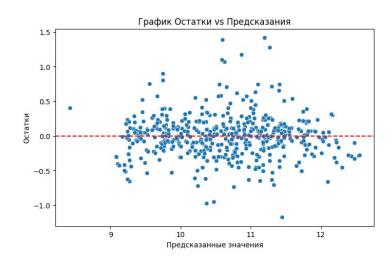
Тест: Бокса-Кокса <u>линейная vs полулогарифмическая</u>

RSS (линейная модель): 374909571109.45 **RSS** (лог-преобразованная модель): 67.12

Статистика LM: 20850.042

Р-значение: 0.0000

Отвергаем Н0: полулогарифмическая модель лучше.



| Dep. Variable: | $\operatorname{salePrice}$ | | R-squared: | | 0.903 | |
|---------------------------------------|----------------------------|----------------------------|-------------------|-------|-----------|----------|
| Model: | OLS | | Adj. R-squared: | | 0.900 | |
| Method: | Least Squares | | F-statistic: | | 434.9 | |
| Date: | Sun, 11 May 2025 | | Prob (F-statistic | | c): 0.00 | |
| Time: | 13:31:32 | | Log-Likelihood: | | 2083.9 | |
| No. Observations: | 929 |) | AIC: | | -4106. | |
| Df Residuals: | 898 | | BIC: | | -3956. | |
| Df Model: | 30 | | | | | |
| Covariance Type: | HC3 | | | | | |
| | coef | std err | \mathbf{z} | P> z | [0.025] | 0.975] |
| const | -11.3353 | 3.946 | -2.872 | 0.004 | -19.070 | -3.601 |
| main_cams | 0.0079 | 0.006 | 1.423 | 0.155 | -0.003 | 0.019 |
| memory | 7.356e-05 | 8.52e-06 | 8.634 | 0.000 | 5.69e-05 | 9.03e-05 |
| height | -0.0006 | 0.002 | -0.268 | 0.788 | -0.005 | 0.004 |
| width | -0.0005 | 0.002 | -0.209 | 0.835 | -0.005 | 0.004 |
| depth | -0.0006 | 0.002 | -0.287 | 0.774 | -0.005 | 0.004 |
| video_resolution_v | 2.569e-06 | 9.99e-07 | 2.573 | 0.010 | 6.12e-07 | 4.53e-06 |
| video_resolution_h | 1.317e-06 | 1.81e-06 | 0.727 | 0.467 | -2.23e-06 | 4.87e-06 |
| $screen_resolution_h$ | 1.676e-05 | 4.35e-06 | 3.854 | 0.000 | 8.24e-06 | 2.53e-05 |
| $screen_resolution_v$ | 1.833e-05 | 3.87e-06 | 4.738 | 0.000 | 1.07e-05 | 2.59e-05 |
| screen_diag | 0.0073 | 0.019 | 0.391 | 0.696 | -0.029 | 0.044 |
| $\operatorname{dust}_{oldsymbol{IP}}$ | -0.0012 | 0.002 | -0.709 | 0.478 | -0.005 | 0.002 |
| water_IP | 0.0041 | 0.001 | 3.292 | 0.001 | 0.002 | 0.007 |
| zoom | 2.913e-05 | 6.68e-05 | 0.436 | 0.663 | -0.000 | 0.000 |
| weight | 0.0001 | 0.000 | 0.706 | 0.480 | -0.000 | 0.000 |
| is_new | 0.0421 | 0.005 | 8.293 | 0.000 | 0.032 | 0.052 |
| battery | -2.727e-06 | 4.89e-06 | -0.558 | 0.577 | -1.23e-05 | 6.85e-06 |
| is_5G | 0.0409 | 0.004 | 10.073 | 0.000 | 0.033 | 0.049 |
| frameless | 0.0071 | 0.004 | 1.658 | 0.097 | -0.001 | 0.015 |
| year | 0.0067 | 0.002 | 3.709 | 0.000 | 0.003 | 0.010 |
| opt_zoom | 0.0020 | 0.001 | 1.545 | 0.122 | -0.001 | 0.005 |
| front_camera_mp_total | 0.0004 | 0.000 | 2.827 | 0.005 | 0.000 | 0.001 |
| main_camera_mp_total | 0.0001 | $5.42\mathrm{e}\text{-}05$ | 2.320 | 0.020 | 1.95e-05 | 0.000 |
| brand_Apple | 0.0687 | 0.015 | 4.553 | 0.000 | 0.039 | 0.098 |
| brand_Samsung | 0.0236 | 0.005 | 4.306 | 0.000 | 0.013 | 0.034 |
| brand_Xiaomi | -0.0005 | 0.004 | -0.120 | 0.904 | -0.008 | 0.007 |
| brand_Tecno | 0.0008 | 0.005 | 0.142 | 0.887 | -0.010 | 0.011 |
| brand_HONOR | 0.0075 | 0.008 | 0.904 | 0.366 | -0.009 | 0.024 |
| brand_HUAWEI | 0.0153 | 0.009 | 1.676 | 0.094 | -0.003 | 0.033 |
| brand_Infinix | 0.0052 | 0.007 | 0.762 | 0.446 | -0.008 | 0.019 |
| $strong_frame$ | 0.0159 | 0.005 | 3.383 | 0.001 | 0.007 | 0.025 |



Выбор функциональной формы

Тест: Рамсея

1. Оценивается исходная линейная модель:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \epsilon$$

- 2. Из неё получают предсказанные значения \hat{y} .
- 3. В расширенную модель добавляют **степени** \hat{y} (обычно \hat{y}^2 , \hat{y}^3):

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \alpha_1 \hat{y}^2 + \alpha_2 \hat{y}^3 + \epsilon$$

- 4. Проверяют **F-тестом**, значимы ли новые коэффициенты (α_1, α_2):
 - ∘ Если **p-value** < $0.05 \rightarrow \text{отвергаем H}_0$ (модель некорректна).
 - ∘ Если **p-value > 0.05** → **нет оснований отвергать H** $_0$ (форма модели адекватна).

Дополнительно добавили признаки с функциями: log, sqrt(), ^2, ^3, ^4, ^5

После оценки незначимости коэффициентов перед огромным количеством переменных, а также сравнением моделей по R^2 регрессоры изменились

| - 1 | | | | |
|-----|----|---------------------|----------------|----------|
| | | Feature | Transformation | R2 |
| | 0 | IP | x^4 | 0.495507 |
| | 1 | P | x^5 | 0.128859 |
| | 2 | brand_Apple | X | 0.241322 |
| | 3 | brand_H0N0R | x | 0.008218 |
| | 4 | brand_HUAWEI | X | 0.001738 |
| | 5 | brand_Infinix | x | 0.033923 |
| | 6 | brand_Samsung | x | 0.075613 |
| | 7 | brand_Tecno | x | 0.072250 |
| | 8 | brand_Xiaomi | X | 0.045041 |
| | 9 | dim_PC1 | log(x) | 0.470167 |
| | 10 | dim_PC2 | x | 0.343538 |
| | 11 | frameless | x | 0.042148 |
| | 12 | is_5G | x | 0.507242 |
| | 13 | is_new | x | 0.000479 |
| | 14 | memory | x | 0.215443 |
| | 15 | opt_zoom | x | 0.266491 |
| | 16 | screen_diag | log(x) | 0.041654 |
| | 17 | screen_resolution_h | x^5 | 0.200900 |
| | 18 | screen_resolution_v | log(x) | 0.111842 |
| | 19 | strong_frame | x | 0.583260 |
| | 20 | weight | x | 0.038507 |
| | 21 | year | x^5 | 0.000311 |
| | 22 | zoom | log(x) | 0.144068 |
| | | | | |

8

Выбросы

Тесты и статистики:

- Леверидж

Леверидж h_{ii} — диагональные элементы матрицы

$$H = X(X^TX)^{-1}X^T$$
 ("hat matrix").

$$h_{ii}>rac{2(k+1)}{n}$$
 — точка с высоким влиянием.

- Стьюдентизированные остатки

$$r_i = rac{e_i}{s\sqrt{1-h_{ii}}}$$

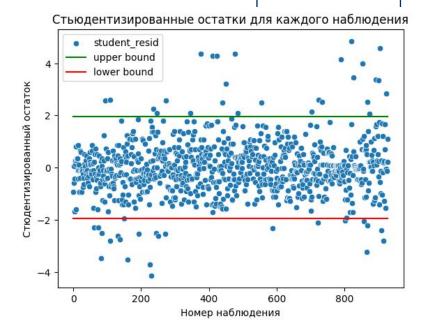
Где:

- ullet $e_i=y_i-\hat{y_i}$ обычный остаток для і-го наблюдения
- ullet s стандартная ошибка остатков всей модели (RMSE)
- h_{ii} леверидж (диагональный элемент матрицы влияния H)

|r_i| > 3 — явный выброс

Удалено 5 выбросов





- DFFITS

Формула

$$DFFITS_i = t_i \sqrt{rac{h_{ii}}{1-h_{ii}}}$$

где t_i — стьюдентизированный остаток, h_{ii} — леверидж.

Интерпретация

ullet $|DFFITS_i| > 2\sqrt{rac{k+1}{n}}$ — точка сильно влияет на модель.



Выводы

```
In(price) = -55.96 + 0.4 In(memory) + 0.7 brand_Apple + 0.47 is_new + 0.292 strong_frame + 0.42 is_5G + 0.2 main_cams + 0.099 In(zoom) + 0.000015 year^2 - 0.0004 (brand_Apple * memory) + 0.00005 (frameless * year) + 0.08 dim_PC2 - 0.000005 P^2 + 0.001 IP^2 - 0.004 (brand_HUWAEI * front_camera_mp_total) + e
```

Попробовали предсказать цену телефона Google Смартфон Google Pixel 7 Pro 12/128GB, который стоит 49.990, у нас получилось 52.360

```
R-squared: 0.902
Adj. R-squared: 0.900
F-statistic: 925.3
Prob (F-statistic): 0.00
Log-Likelihood: -106.57
AIC: 245.1
BIC: 322.4
```



Квантильная регрессия

Квантили: 0.1, 0.5, 0.75, 0.9

